

실험 상세 데이터 및 보조 분석

본 부록은 본문 2장 요약 보고서에서 분량 제약으로 생략된 원본 데이터 전체를 수록합니다. 본문의 모든 수치는 이 부록의 원본 데이터에서 도출되었습니다.

수록 항목

- A. Baseline 학습 곡선 Epoch 상세
- B. 클래스별 데이터 분할 현황
- C. 병목 클래스 진단 상세
- D. 층별 파라미터 구성
- E. Receptive Field 계산 근거
- F. 측정 체계 상세
- G. 전체 실험 상세 (트랙A / 트랙B)
- H. 클래스별 Recall 전체 매트릭스 (#1-#12)
- I. 최종 모델 클래스별 성능 (Test)
- J. Scratch Precision·Recall 동반 개선 추이
- K. 한계 및 향후 과제
- L. 실행 환경 및 재현 방법
- M. 계산 근거

A. Baseline 학습 곡선 Epoch 상세 (실험 #1)

Baseline은 Early Stopping 없이 30 epoch 학습. Valid Loss는 6 epoch(0.4507)에서 최저를 기록한 후 2.8배 상승했다. 6 epoch 이후 학습된 내용은 일반화에 기여하지 않았음을 보여준다.

Epoch	Train Loss	Valid Loss	Train Acc	Valid Acc	비고
1	0.9045	0.6819	66.33%	75.07%	학습 초기
6	0.3049	0.4507	89.34%	84.68%	Valid Loss 최저 → 과적합 시작점
10	0.1061	0.5831	96.60%	83.17%	Valid Loss 반등 구간
20	0.0218	1.0390	99.41%	82.90%	Train-Valid 격차 확대
30	0.0067	1.2567	99.87%	82.75%	과적합 극대. Valid Loss 2.8배 상승

* best epoch(28) 가중치 기준 Valid-Macro-F1 평가. 따라서 Baseline 성능 수치는 30 epoch 최종 상태보다 유리하게 측정되어 본문의 개선폭은 보수적 추정이다.

B. 클래스별 데이터 분할 현황

stratified 60:20:20 분할. Near-full 149장이 89/30/30으로 균등 배분되어 Valid·Test 각 30건이다.

클래스	Train	Valid	Test	전체	비율 (전체 기준)
Edge-Ring	5,808	1,936	1,936	9,680	최다 (50.5%)
Edge-Loc	3,113	1,038	1,038	5,189	27.1%
none	3,000	1,000	1,000	5,000	26.1% (샘플링 제한)
Center	2,576	859	859	4,294	22.4%
Loc	2,156	718	719	3,593	18.8%
Scratch	716	239	238	1,193	6.2%
Random	520	173	173	866	4.5%
Donut	333	111	111	555	2.9%
Near-full	89	30	30	149	최소 (0.8%) — Valid 30건

* none 클래스는 원본 147,431장에서 5,000장으로 샘플링 제한. 불량 전량 25,519장 + 정상 5,000장 = 30,519장 사용.

C. 병목 클래스 진단 상세 (Baseline 기준)

학습 데이터가 가장 적은 Near-full(89장)이 Recall 0.933인 반면, 8배 많은 Scratch(716장)가 0.213으로 최하위. 병목은 샘플 수가 아닌 패턴의 시각적 구별 가능성이다.

클래스	Train 건수	Recall	F1	Precision	해석
Near-full	89	0.933	0.966	—	소량임에도 고성능 — 패턴이 타 유형과 명확히 구분됨
Random	520	0.873	0.844	—	정상 범위
Donut	333	0.829	0.833	—	정상 범위
Loc	2,156	0.663	0.696	—	Scratch와 상호 혼동 의심
Scratch	716	0.213	0.269	0.319	8배 많은 데이터에도 최하위 — 샘플 수가 아닌 패턴 구별 가능성이 병목

D. 층별 파라미터 구성 (BaselineCNN)

층	파라미터 수	전체 비중	구조	역할
Conv1 (1→32)	320	0.0%	3×3 Conv	지역 특징 추출
Conv2 (32→64)	18,496	2.2%	3×3 Conv	중간 특징 추출
FC1 (12544→64)	802,880	97.6%	위치×채널 전체 연결	좌표 암기 — 과적합 주원인
FC2 (64→9)	585	0.1%	선형 분류기	클래스 출력

층	파라미터 수	전체 비중	구조	역할
합계	822,281	100%	—	—

FC1 단일 층이 전체 파라미터의 97.6%를 점유한다. Conv는 가중치 공유로 형태를 학습하나, FC는 12,544개 입력에 독립 가중치를 부여하여 좌표 조합을 암기한다. 이것이 과적합과 Scratch 미검출의 구조적 원인이다.

E. Receptive Field 계산 근거

아래 공식으로 각 Conv+Pool 레이어를 순서대로 누적하여 최종 RF를 산출.

```
rf_calc(layers):  rf, jump = 1, 1
    for (k, s) in layers:  rf += (k-1) * jump;  jump *= s
```

모델	레이어 구성 [(kernel, stride)]	RF 결과
BaselineCNN (Baseline)	[(3,1),(2,2),(3,1),(2,2)]	10px (입력 64px의 2.4%)
ImprovedCNN (최종)	[(3,1),(2,2),(3,1),(2,2),(3,1),(2,2),(3,1),(2,2)]	46px (입력의 52%)

Conv 블록을 2→4개로 늘리고 padding=1을 적용하여 Conv 단계에서는 크기를 유지, Pooling에서만 축소함으로써 4블록 구성 및 RF 확대를 동시에 달성했다.

F. 측정 체계 상세

데이터 분할: Train/Valid/Test = 60:20:20 stratified. 모든 하이퍼파라미터 판단은 Valid만을 근거로 하고, Test는 최종 조합 확정 후 1회만 평가했다.

Seed 고정: random / numpy / torch / cuda를 seed=42로 완전 고정. Baseline은 데이터 분할만 고정되어 초기화·배치 셔플이 변동했다. 성능 차이가 기법에서만 기인하도록 통제.

평가 지표: Valid-Macro-F1을 감시 지표로 사용. Accuracy가 하락해도 Macro-F1이 상승하면 개선으로 판정.

Valid-Recall(소수)는 Near-full·Donut·Random 3종 Recall 평균.

Early Stopping: Valid-Macro-F1 감시. patience만큼 개선 없으면 중단하고 최고 시점 가중치를 복원. 실험 #1은 ES 없이 30 epoch 학습 후 best epoch(28) 가중치로 평가.

G-1. 전체 실험 상세 — 트랙A (규제 중심, BaselineCNN)

lr=1e-3, patience=5. 직전 실험 대비 한 요소만 변경한 누적 구성.

#	실험 개요	Train Acc	Valid Acc	Macro-F1	Recall(소수)	비고
1	Baseline (30ep, ES 없음)	99.01%	84.06%	0.7851	0.8783	gap 14.95%p. 과적합 관찰용 기준
2	+ Early Stopping (patience=5)	91.49%	83.98%	0.7914	0.9340	best ep7. 트랙A 최고

#	실험 개요	Train Acc	Valid Acc	Macro-F1	Recall(소수)	비고
3	+ Class Weight (balanced)	90.33%	81.37%	0.7639 ▼	0.8686	Near-full 이미 0.933, 효과 없음. Acc 하락
4	+ Dropout (p=0.4)	86.89%	81.82%	0.7623 ▼	0.8898	무효
5	+ Weight Decay (1e-4)	76.54%	79.87%	0.7529 ▼	0.9359	gap -3.33%p → 과소적합. 트랙A 기각

Recall(소수) = Near-full · Donut · Random 3종 Recall 평균. 트랙A는 규제 3종이 모두 Macro-F1을 악화시켜 기각되었다.

G-2. 전체 실험 상세 — 트랙B (구조 재설계, lr=1e-3, patience=10, epochs≤80)

#	실험 개요	Train Acc	Valid Acc	Macro-F1	Recall(소수)	비고
6	Baseline + ES (patience=10)	99.54%	83.55%	0.7835	0.8985	트랙B 기준점. patience 변경 브릿지
7	+ ImprovedCNN (Conv4+BN+GAP)	95.12%	78.83%	0.7886	0.8973	Scratch F1 2.7배 ↑ . best ep10, 학습 불안정
8	+ LR Scheduler (ReduceLR max,0.5,p4)	99.87%	88.12%	0.8606	0.9258	단일 최대 기여 +0.072
9	+ Dropout (p=0.3)	97.56%	87.19%	0.8526	0.8967	무효 (-0.008)
10	+ Weight Decay (1e-5)	97.52%	88.02%	0.8550	0.9430	±0.002 — 노이즈 수준
11	+ LeakyReLU (slope=0.01)	95.30%	88.12%	0.8527	0.8796	Macro-F1 -0.002, gap 개선. 최종 유지
12	+ Augmentation (rot90/flip) → 최종	93.24%	91.96%	0.9003	0.9438	gap 1.29%p. 목표 5개 전부 달성

* 모든 지표는 Valid-Macro-F1 최고 시점(best epoch) 모델 기준.

H. 클래스별 Recall 전체 매트릭스 (Valid 기준, #1-#12)

건수는 전체 데이터 기준, Recall은 Valid(6,104건) 기준. #12 열은 최종 모델.

클래스	#1	#2	#3	#4	#5	#6	#7	#8	#9	#10	#11	#12
Edge-Ring	0.980	0.988	0.939	0.972	0.951	0.972	0.803	0.976	0.995	0.983	0.966	0.989
Edge-Loc	0.796	0.791	0.790	0.774	0.780	0.761	0.544	0.878	0.883	0.751	0.822	0.872
none	0.797	0.729	0.791	0.726	0.664	0.769	0.934	0.840	0.733	0.848	0.850	0.851
Center	0.945	0.928	0.942	0.903	0.900	0.952	0.953	0.964	0.922	0.965	0.973	0.963
Loc	0.663	0.701	0.574	0.666	0.574	0.721	0.740	0.652	0.687	0.776	0.787	0.873
Scratch	0.213	0.310	0.255	0.259	0.360	0.197	0.569	0.661	0.795	0.695	0.544	0.824

클래스	#1	#2	#3	#4	#5	#6	#7	#8	#9	#10	#11	#12
Random	0.873	0.907	0.786	0.850	0.925	0.861	0.890	0.931	0.861	0.919	0.931	0.931
Donut	0.829	0.928	0.820	0.820	0.883	0.901	0.802	0.847	0.829	0.910	0.775	0.901
Near-full	0.933	0.967	1.000	1.000	1.000	0.933	1.000	1.000	1.000	1.000	0.933	1.000

- Scratch(병목): #6→#7 구간에서 0.197→0.569(2.9배). 구조 재설계 직접 효과. #12에서 0.824.
- Loc: Scratch와 상호 혼동 관계로 추정. Scratch 개선과 함께 0.663→0.873으로 동반 상승.
- Near-full: Valid 30건으로 Recall 1건=3.33%p. 미세 변화는 해석 대상에서 제외.
- Edge-Ring·Center: 전 실험 0.9 이상 유지. 시각적으로 명확한 패턴.

I. 최종 모델 클래스별 성능 (Test, 실험 #12)

클래스 (Test)	Precision	Recall	F1	Support
Edge-Ring	0.9819	0.9819	0.9819	1,936
Center	0.9387	0.9627	0.9506	859
none	0.9365	0.8400	0.8856	1,000
Edge-Loc	0.8701	0.8844	0.8772	1,038
Random	0.8163	0.9249	0.8672	173
Near-full	0.8667	0.8667	0.8667	30
Scratch	0.8354	0.8529	0.8441	238
Loc	0.8147	0.8498	0.8319	719
Donut	0.8017	0.8378	0.8194	111
macro avg	0.8736	0.8890	0.8805	6,104

* macro avg는 클래스 가중치 없는 단순 평균. 9개 클래스 전부 F1 0.80 이상 달성.

J. Scratch Precision·Recall 동반 개선 추이

Recall만 상승한 경우는 과잉 검출을 의미하여 정상품 폐기 비용을 발생시킨다. Precision·Recall의 동반 개선이 실질적 판별 능력 획득의 판정 기준이다.

시점	Precision	Recall	해석
Baseline(#1 Test)	0.3187	0.2143	10건 중 8건 미검출. P/R 모두 극저
실험 #11 (Valid)	0.9286	0.5439	Recall 50% 돌파. 단 Precision 과잉 — 오검출 위험 내포
최종 #12 (Test)	0.8354	0.8529	P·R 균형 달성. 실질적 판별 능력 획득 확인

K. 한계 및 향후 과제

Near-full 통계 해상도. Valid/Test 각 30건으로 Recall 1건=3.33%p. Baseline Valid 0.933 vs Test 0.700 편차(0.23)가 이를 보여준다. 해당 클래스 미세 변화는 해석 대상에서 제외했다.

단일 Seed. 전 실험을 seed=42로 수행. Macro-F1 차이 0.01 미만인 실험 쌍(#9·#10·#11)은 seed 변경 시 순위 역전 가능. 반복 실행을 통한 표준편차 산출이 필요하다.

LeakyReLU 확정 유보. 실험 #11의 Macro-F1 -0.0023은 Valid 6,104건 기준 약 15건, 노이즈 범위. gap 개선(9.49%→7.18%p)을 고려해 최종 조합에 유지했으나 ReLU 복원 대조 실험을 수행하지 않아 확정적 판단은 유보한다.

구조 재설계·LR Scheduler 상호작용 미분리. Baseline에 LR Scheduler만 적용한 대조군이 없어 스케줄러 단독 효과와 구조 의존적 효과를 분리하지 못했다.

하이퍼파라미터 탐색적 결정. Dropout 0.3, Weight Decay 1e-5, LeakyReLU slope 0.01 등은 체계적 탐색이 아닌 선행 관찰 기반 설정값이다.

입력 해상도 제약. 전 실험을 64×64로 수행. Scratch 등 선형 결합은 리사이즈 시 정보 손실이 발생한다. 96×96 또는 128×128 적용 시 추가 개선 여지가 있으나 연산 비용이 제공으로 증가하여 본 범위에서는 시도하지 않았다.

향후 검토 기법. ① Focal Loss($\gamma=2$)로 난이도 기반 가중 — Scratch·Loc 등 판별 어려운 클래스 집중. ② ResNet 계열 전이학습. ③ Augmentation 범위 확대(약한 노이즈 주입, 부분 마스킹). 단, 각 기법은 Valid-Macro-F1 기준으로 단일 변인 검증을 거쳐야 한다.

L. 실행 환경 및 재현 방법

Python 3.11 / torch · scikit-learn · numpy · pandas · scikit-image

디바이스: Apple Silicon MPS

Seed: 42 (random / numpy / torch / cuda 전체 고정)

데이터: WM-811K (LSWMD.pkl)

원본 811,457장 → 30,519장 (불량 전량 25,519 + 정상 5,000 샘플링)

분할: Train 18,311 / Valid 6,104 / Test 6,104 (stratified 60:20:20)

전처리: 64×64 리사이즈 (Nearest Neighbor, order=0), 픽셀값 0/1/2 유지

재현 순서: 01-prep.ipynb → split.npz 생성 → 02-exp.ipynb 실행

코드 링크: https://github.com/ahrdyrxkddhfl/SKALA_CNN-Optimization

M. 계산 근거

Receptive Field 공식

```
rf, jump = 1, 1
for (kernel, stride) in layers:
    rf += (kernel - 1) * jump
    jump *= stride
```

파라미터 수 계산

Conv: 출력채널 $\times$ (커널 H $\times$ 커널 W $\times$ 입력채널) + 출력채널

FC: 입력 $\times$ 출력 + 출력

BaselineCNN FC1: $12,544 \times 64 + 64 = 802,880$ (전체의 97.6%)

ImprovedCNN Head: $128 \times 9 + 9 = 1,161$

Class Weight (balanced)

$w_c = \text{전체 표본 수} / (\text{클래스 수} \times \text{클래스 } c \text{의 표본 수})$

예) *Near-full*: $18,311 / (9 \times 89) = 22.86$