

웨이퍼맵 불량 분류 CNN 최적화 보고서

작성자	황도희, 이소정
작성일	2026-08-07
코드	https://github.com/ahrdyrxkddhf1/SKALA_CNN-Optimization

데이터셋: LSWMD WM-811K 분류 클래스: 9종 (불량 8 + 정상 1) 평가 기준: Macro-F1 / 클래스별 Recall

SUMMARY

Baseline CNN은 Train 99.01% / Valid 84.06%로 **14.95%p의 과적합 격차**를 보였다. Accuracy 82.7%는 병목 클래스 Scratch의 Recall 0.213을 은폐하고 있었다.

진단 결과 파라미터 97.6%가 단일 FC 층에 집중되고 Conv의 Receptive Field가 10px(입력 64px의 2.4%)에 불과했다. 웨이퍼맵 불량량의 대부분은 전역 패턴이므로 Conv가 인식하지 못하고 FC의 위치 암기가 이를 대체하는 구조적 결함이 과적합과 Scratch 미검출을 동시에 유발하고 있었다.

트랙 A(규제 중심)에서 Class Weight·Dropout·Weight Decay는 Macro-F1을 0.7914→0.7529로 단조 악화시켰다. 실험 #5는 Train 76.54%의 과소적합에 도달하여, 결함 구조에 규제를 가하면 학습 능력만 저하됨을 확인하고 트랙 A를 기각했다.

트랙 B(구조 재설계)에서 Conv 4블록+BatchNorm+GAP으로 RF를 46px로 확대하고 파라미터를 71% 감축하자 Scratch F1이 2.7배 개선되어 진단이 검증되었다. 이후 LR Scheduler(+0.072)로 학습을 안정화하고, 도메인 지식 기반 회전·반전 증강(+0.048)으로 암기 가능성을 차단했다.

최종 성능(Test, 1회 평가): **Accuracy 0.9140 / Macro-F1 0.8805 / Recall(mean) 0.8890**으로 목표 5개 전부 달성. Baseline 대비 Macro-F1 +0.1253, 격차 14.95%p → 1.29%p. Train 93.24% 유지로 학습 능력을 희생하지 않고 암기만 제거했다. 병목 클래스 Scratch F1은 0.2563 → 0.8441(3.3배) 로 진단의 타당성이 검증되었다.

01 최적화 목적 및 목표

반도체 웨이퍼맵 불량량은 공정 이상의 지문이다. 불량 미검출(FN)은 결함 웨이퍼의 후속 공정 통과로 누적 손실을 유발하지만, 오검출(FP)은 재검사 비용에 그친다. 모든 불량 유형을 고르게 검출하는 능력을 우선 목표로 설정했다.

순위	목표 지표	기준	설정 근거
1순위	Macro-F1	≥ 0.75	클래스 불균형(65:1)에서 Accuracy는 다수 클래스에 지배됨. Macro-F1은 모든 클래스를 1/9 가중으로 평균하여 소수 클래스 실패가 즉시 반영됨
1순위	희귀 Recall(Near-full, Scratch)	≥ 0.50	0.50 미만은 절반 이상 미검출 — 자동 검사 시스템으로 신뢰 불가. 해당 불량은 후속 공정 전체 영향
2순위	Accuracy	≥ 0.90	전반적 분류 신뢰도 기준

순위	목표 지표	기준	설정 근거
3순위	Train-Valid 격차	≤ 5%p	Baseline 14.95%p를 1/3 수준으로 낮추는 것을 실질적 개선 기준선으로 설정

02 이 전략을 선택한 이유 — 진단과 설계 판단 논리

병목의 재정의. 클래스 불균형(65:1)을 보고 통상적으로 Class Weight를 적용하겠으나, 가장 샘플이 적은 Near-full(89장)의 Recall이 이미 0.933이고, 716장인 Scratch가 0.213으로 최저였다. 샘플 수가 아닌 패턴의 시각적 구별 가능성이 병목이었다.

구조적 원인 특징. RF 10px는 전역 패턴 인식이 불가능하다. FC에 파라미터가 97.6% 집중된 것은 Conv가 판단을 수행하지 못하고 FC의 좌표 암기가 대체하는 결과다. 원인이 용량 과다가 아닌 파라미터 배치의 구조적 결함이므로 규제(트랙 A)는 작동하지 않고 구조 재설계(트랙 B)가 필요하다는 가설을 세웠다.

데이터 불균형 대응 방침. ① Class Weight: 손실 함수만 왜곡할 뿐 소수 클래스의 표본 다양성을 늘리지 못함. ② SMOTE: 0/1/2 이산값 이미지에 물리적으로 존재할 수 없는 보간값 생성 → 도메인 부적합. ③ 언더샘플링: 최소 클래스 89장 기준 전체 데이터를 800장으로 붓고. 결론: 웨이퍼는 원형이므로 90도 회전·좌우·상하 반전에 라벨이 보존되는 도메인 지식 기반 Augmentation을 선택했다.

단일 변인 원칙. 각 실험은 직전 대비 한 요소만 변경하여 인접 두 실험의 성능 차이가 해당 요소의 기여도에 대응되도록 설계했다.

03 무엇이 효과가 있었는가 — 실험별 기여도

#	핵심 변경	Train	Valid	Macro-F1	Scratch F1	판정 / 근거
1	Baseline	99.01%	84.06%	0.7851	0.2563	과적합 gap 14.95%p. Scratch 0.213으로 기준 미달
2	+ Early Stopping	91.49%	83.98%	0.7914	0.310	트랙 A 최고, 소폭 개선
3-5	+ Class Weight / Dropout / WD	76.54%	79.87%	0.7529 ▼	—	단조 악화. #5에서 gap -3.33%p이나 Train 76% — 과소적합. 트랙 A 각각
7	+ 구조 재설계(Conv 4블록+GAP)	95.12%	78.83%	0.7886	0.655 ▲▲	Scratch F1 2.7배. RF 10→46px 진단 검증
8	+ LR Scheduler	99.87%	88.12%	0.8606 ▲	0.730 ▲	단일 최대 기여 +0.072. 구조 잠재력 실현
12	+ Augmentation (회전·반전)→ 최종	93.24%	91.96%	0.9003 ▲	0.824 ▲	gap 1.29%p. Train 93% 유지하며 암기만 제거

핵심 관찰 ① 구조 재설계(#7)는 전체 성능을 즉시 올리지 않았으나 Scratch F1을 2.7배 개선해 진단을 검증했다. LR Scheduler(#8)가 불안정해진 학습을 안정화하며 +0.072를 추가했다. 두 요소는 독립적 기여가 아닌 순차적 의존 관계다.

핵심 관찰 ② Augmentation(#12)은 Train Accuracy를 낮추는 동시에 Valid를 높여 gap 1.29%p를 달성했다. 기존 규제가 표현력 자체를 축소(#5: Train 76%)하는 방식인 반면, 증강은 표현력을 유지한 채 암기 가능성만 제거한다는 점에서 메커니즘이 근본적으로 다르다.

04 비즈니스 기준 최적 성능 및 해석

지표	Baseline	최종 (#12)	변화	판정
Accuracy	0.8270	0.9140	+0.0870	✓ 달성 (≥0.90)
Macro-F1	0.7552	0.8805	+0.1253	✓ 달성 (≥0.75)
Near-full Recall	0.7000	0.8667	+0.1667	✓ 달성 (≥0.50)
Scratch Recall	0.2143	0.8529	+0.6386	✓ 달성 (기준 미달 → 달성)
Train-Valid 격차	14.95%p	1.29%p	-91%	✓ 달성 (≤5%p)
파라미터	822,281	242,121	-71%	경량화 동시 달성

Scratch Recall 0.213 → 0.853(4.0배). 10건 중 8건을 놓치던 상태에서 8건 이상을 검출한다. Scratch는 이송 설비의 기계적 접촉을 시사하므로 이를 검출해야 설비 점검으로 연계된다. "특정 불량이 검출되지 않는다"는 현장 문제가 해결된 것이다.

Macro-F1 +0.1253 vs Accuracy +0.0870. Macro-F1 개선폭이 더 크다는 것은 다수 클래스를 더 잘 맞혀서가 아니라 약한 클래스들을 끌어올려 성능이 향상되었음을 의미한다. 최저 F1이 0.2563 → 0.8194로 상승하여 특정 유형만 잡는 편향 모델이 아님을 확인했다.

격차 축소의 의미. 1.29%p는 실험 #5(-3.33%p)보다 수치가 크나, #5는 Train 76.54%의 과소적합이었다. 최종 모델은 Train 93.24%를 유지한 상태에서 격차를 축소했다. 격차 축소만으로 과적합 해소를 주장할 수 없으며, 학습 능력 유지가 함께 확인되어야 한다.

Test 일반화 확인. Valid(0.9003) 대비 Test(0.8805) Macro-F1 차이 0.0198. Baseline의 Valid→Test 하락폭(0.0299)보다 작아 최적화 과정에서 Valid에 과적합되지 않았음을 확인했다.